الجامعة السورية الخاصة
كلية هندسة الذكاء الصنعي
قسم هندسة الذكاء الصنعي وعلوم البيانات الذكية

Arabic Automated Essay Scoring

(نظام تقييم المقالات العربية الآلي)

الدراسات المرجعية

إعداد:

مجد سامر عثمان

بإشراف:

الدكتورة ماجدة البكور

المهندسة وسام السحلي

1448-1447 هـ | 2026-2025 م

1- مقدمة

تستعرض هذه الورقة أهم الدراسات المرجعية الحديثة (2025–2026) ذات الصلة بمشروع التقييم الآلي للمقالات العربية مع توليد تغذية راجعة للطالب. ولكل دراسة نذكر البيانات المستخدمة، والأدوات، والمنهجية، والنتائج، ومعايير التقييم، ثم فائدتها للمشروع.

2- الدراسات المرجعية

2-1- LAILA (Bashendy et al., 2026) [1]

- **البيانات:** 7,859 مقالة لطلاب المرحلة الثانوية في قطر على 8 مواضيع (5 إقناعية و3 تفسيرية)، مصحّحة على 7 صفات: الصلة REL من 0 إلى 2، والتنظيم والمفردات والأسلوب والتطوير والإملاء والقواعد من 0 إلى 5، والدرجة الكلية من 0 إلى 32. وبلغ اتفاق المصححين QWK بين 0.66 و0.75.
- **الأدوات:** scikit-learn وXGBoost وPyTorch وHugging Face Transformers وOptuna وCAMeL Tools.
- **المنهجية:** نماذج ميزات (816 ميزة) وAraBERT وAraT5 ونماذج لغوية عربية (Fanar وALLaM)، بإعدادين: التدريب والاختبار على الموضوع نفسه (5 أجزاء)، والاختبار على مواضيع جديدة (8 أجزاء).
- **النتائج:** AraBERT حقق 0.833 للدرجة الكلية على الموضوع نفسه؛ وأفضل متوسط على المواضيع الجديدة 0.597 لنموذج MOOSE؛ بينما حقق Fanar مع 5 أمثلة 0.575 فقط.
- **معايير التقييم:** QWK لكل صفة وللدرجة الكلية.
- **الفائدة للمشروع:** مجموعة البيانات الأساسية، وخطوط الأساس الرسمية التي نقارن بها.

2-2- Qayyem & TRATES (Elbahnasawi et al., 2026) [2][9]

- **البيانات:** LAILA بالتقسيمات الرسمية على المواضيع الجديدة.
- **الأدوات:** Next.js وFastAPI وPostgreSQL، ونموذج Fanar-1-9B لاستخراج الميزات.
- **المنهجية:** منصة تصحيح عربية تضم RF وXGB وMOOSE وTRATES. ويحوّل TRATES الـ Rubric إلى أسئلة يجيب عنها نموذج لغوي لكل مقالة، وتدخل الإجابات ميزاتٍ في شبكة عصبية.
- **النتائج:** TRATES أعلى نتيجة منشورة على المواضيع الجديدة: متوسط 0.653، وREL بقيمة 0.557 مقابل 0.411 لنموذج MOOSE، لكنه أبطأ (30 ثانية لكل مقالة).

- **معايير التقييم:** QWK، وزمن التصحيح لكل مقالة.
- **الفائدة للمشروع:** أقوى خط أساس حالي. والمنصة لا تولّد ملاحظات للطالب، وهي الفجوة التي يعالجها المشروع.

2-3- MAPLE (Albatarni et al., 2026) [3]

- **البيانات:** LAILA، ومجموعتا ELLIPSE وASAP الإنكليزيتان.
- **الأدوات:** AraBERTv2 وPyTorch.
- **المنهجية:** تعلّم التعلّم (Meta-Learning) بشبكات Prototypical، مع إدخال نص الموضوع والـ Rubric و816 ميزة لغوية.
- **النتائج:** متوسط 0.619 على المواضيع الجديدة في LAILA، وأضاف إدخال الموضوع والـ Rubric نحو 1.3 نقطة، لكن REL بقيت ضعيفة (0.290).
- **معايير التقييم:** QWK.
- **الفائدة للمشروع:** إدخال نص الموضوع يحسّن التعميم، وصفة REL تحتاج معالجة خاصة.

2-4- TAQEEM 2025 (Bashendy et al., 2025) [4]

- **البيانات:** 1,265 مقالة؛ التدريب على موضوعين (425 مقالة)، والاختبار على موضوعين جديدين (840 مقالة).
- **الأدوات:** GPT-4o وGPT-4.1 وAraBERTv02.
- **المنهجية:** مسابقة مشتركة بمهمتين: الدرجة الكلية، والصفات السبع، على مواضيع لم تُرَ في التدريب.
- **النتائج:** GPT-4o مع Rubric حقق 0.751 للدرجة الكلية و0.652 للصفات، مقابل 0.639 و0.472 لنموذج AraBERTv02.
- **معايير التقييم:** QWK وMSE وRMSE.
- **الفائدة للمشروع:** اختبار خارجي لنموذج المشروع على الموضوعين 9 و10.

2-5- Feature Engineering is not Dead (Sayed et al., 2025) [5]

- **البيانات:** 620 مقالة (من TAQEEM وQAES) على 4 مواضيع.
- **الأدوات:** CAMeL Tools وCAMeL Parser وCAMeLBERT، والميزات منشورة على GitHub.
- **المنهجية:** 816 ميزة (سطحية، ومقروئية، ومعجمية، ودلالية، ونحوية) مع RF وXGB وNN، ومقارنتها بنماذج لغوية عربية.

- **النتائج:** RF حقق متوسط 0.294 مقابل 0.280 لأفضل نموذج لغوي (Fanar)، وكانت الميزات الدلالية الأهم لصفة REL.
- **معايير التقييم:** QWK.
- **الفائدة للمشروع:** يدعم منهج الميزات المعتمد في المشروع، ويؤكد أن REL تحتاج مقارنة المقال بنص الموضوع.

2-6- Structured Prompting (Al Mandhari et al., 2026) [6]

- **البيانات:** QAES (195 مقالة، 7 صفات).
- **الأدوات:** 8 نماذج لغوية، منها ChatGPT-4 وFanar وALLaM وQwen وJais.
- **المنهجية:** ثلاثة مستويات توجيه دون تدريب: تصحيح مباشر، ومحاكاة 5 مصححين، ودليل لكل صفة مع أمثلة.
- **النتائج:** أفضل نتيجة لنموذج Fanar بقيمة 0.284 فقط، مقابل اتفاق بشري 0.72.
- **معايير التقييم:** QWK مع فترات ثقة Bootstrap.
- **الفائدة للمشروع:** النموذج اللغوي وحده لا يصلح لإعطاء الدرجة، لذا يُستخدم في المشروع للشرح فقط.

2-7- Literature Review (Dahimi et al., 2026) [7]

- **البيانات:** 10 مجموعات بيانات عربية، أكبرها LAILA.
- **المنهجية:** مراجعة أعمال 2020–2025 في التصحيح الآلي العربي، وتصنيفها وفق 5 أبعاد منها توليد الملاحظات.
- **النتائج:** AraBERT المدرَّب حقق 0.88، والنماذج اللغوية بين 0.58 و0.67؛ ولا يوجد نظام عربي لتصحيح المقالات يولّد ملاحظات.
- **معايير التقييم الشائعة:** QWK، ثم Accuracy وF1 وRMSE.
- **الفائدة للمشروع:** تثبت أن توليد الملاحظات للطالب فجوة بحثية قائمة.

2-8- Beyond Score Prediction (Jin et al., 2026) [8]

- **البيانات:** ASAP (12,978 مقالة إنكليزية على 8 مواضيع).
- **الأدوات:** GPT-5.5 وDeepSeek-V4-Pro محكّمين لتقييم الملاحظات.
- **المنهجية:** تدريب نموذج لغوي بالتعلم المعزّز ليكتب الملاحظات ثم الدرجة، وتقييم الملاحظات بـ 166 بنداً في أربعة أبعاد: التغطية، والشاهد من النص، والأمانة للنص، والسلامة.

- **النتائج:** QWK بلغ 0.803 مقابل 0.805 للمصحح البشري، ووافق تقييم الملاحظات رأي الخبير في 93% من الحالات مقابل 53.5% لمقياس BERTScore.
- **معايير التقييم:** QWK للدرجة، ومقياس RFE للملاحظات.
- **الفائدة للمشروع:** معايير جاهزة لتقييم الملاحظات التي يكتبها وكيل المشروع.

3- ملخص المقارنة

يلخص الجدول 1 الدراسات الثماني من حيث البيانات والأدوات والمنهجية ومعايير التقييم والنتائج. ولا تصح مقارنة الأرقام بين مجموعات بيانات مختلفة.

#	الدراسة	البيانات	الأدوات والنماذج	المنهجية	معايير التقييم	النتائج الرئيسية
1	**LAILA** Bashendy et al., EACL 2026	7,859 مقالة عربية لطلاب ثانوي في قطر، على 8 مواضيع، بسبع صفات ودرجة كلية من 0 إلى 32	AraBERT، AraT5، XGBoost، Random Forest، Fanar، ALLaM، CAMeL Tools	بناء مجموعة بيانات وتجربة نماذج مرجعية بإعدادين: نفس الموضوع، ومواضيع جديدة	QWK لكل صفة وللدرجة الكلية	على الموضوع نفسه: حقق AraBERT درجة 0.833 للدرجة الكلية. وعلى المواضيع الجديدة: حقق MOOSE متوسطاً قدره 0.597.
2	**Qayyem + TRATES** Elbahnasawi et al., ACL 2026	LAILA، والاختبار على مواضيع جديدة	Fanar-1-9B، XGBoost، Random Forest، MOOSE، FastAPI، Next.js	منصة تصحيح؛ نموذج لغوي يحوّل معايير التصحيح (Rubric) إلى أسئلة، وإجاباتها ميزات لشبكة عصبية	QWK، وزمن التصحيح	أعلى نتيجة منشورة: متوسط 0.653. وصفة الصلة بالموضوع: 0.557 مقابل 0.411 لنموذج MOOSE.
3	**MAPLE** Albatarni et al., ACL 2026	LAILA، ومجموعتا ASAP وELLIPSE الإنكليزيتان	AraBERTv2، PyTorch	تعلّم التعلّم (Meta-Learning) مع إدخال نص الموضوع ومعايير التصحيح و816 ميزة لغوية	QWK	متوسط 0.619 على المواضيع الجديدة، وصفة الصلة بالموضوع بقيت ضعيفة عند 0.290.
4	**TAQEEM 2025** Bashendy et al., ArabicNLP 2025	1,265 مقالة: تدريب على موضوعين، واختبار على موضوعين جديدين	GPT-4o، GPT-4.1، AraBERTv02	مسابقة مشتركة بمهمتين: الدرجة الكلية، والصفات السبع	QWK، RMSE	حقق GPT-4o درجة 0.751 للدرجة الكلية و0.652 للصفات، مقابل 0.639 و0.472 لنموذج AraBERT.
5	**Feature Engineering is not Dead** Sayed et al., ArabicNLP 2025	620 مقالة على 4 مواضيع	CAMeL Tools، CAMeLBERT، Random Forest، XGBoost، Fanar	816 ميزة لغوية (سطحية، ودلالية، ونحوية، ومقروئية) ومقارنتها بالنماذج اللغوية	QWK	نموذج الميزات حقق 0.294 مقابل 0.280 لأفضل نموذج لغوي، والميزات الدلالية الأهم لصفة الصلة.

#	الدراسة	البيانات	الأدوات والنماذج	المنهجية	معايير التقييم	النتائج الرئيسية
6	**Structured Prompting** Al Mandhari et al., LREC 2026	195 مقالة جامعية من مجموعة QAES بسبع صفات	8 نماذج لغوية، منها ChatGPT-4 وFanar وALLaM وQwen وJais	تصحيح بالتوجيه فقط بثلاثة مستويات، دون أي تدريب	QWK مع فترات ثقة	أفضل نتيجة 0.284 لنموذج Fanar، مقابل اتفاق بشري يبلغ 0.72.
7	**Literature Review** Dahimi et al., NCMAI 2026	10 مجموعات بيانات عربية	لا يوجد (دراسة مراجعة)	مراجعة أعمال 2020–2025 وتصنيفها بخمسة أبعاد	QWK، F1، RMSE	لا يوجد نظام عربي يولّد ملاحظات للطالب. حقق AraBERT المدرَّب 0.88، والنماذج اللغوية بين 0.58 و0.67.
8	**Beyond Score Prediction** Jin et al., arXiv 2026	12,978 مقالة إنكليزية من مجموعة ASAP	GPT-5.5 وDeepSeek-V4-Pro محكّمين للملاحظات	تعلّم معزّز ليكتب النموذج الملاحظات ثم الدرجة، وتقييم الملاحظات بـ 166 بنداً	QWK، ومقياس RFE للملاحظات	بلغ اتفاق QWK قيمة 0.803 مقابل 0.805 للمصحح البشري، ووافق تقييم الملاحظات رأي الخبير في 93% من الحالات.

الجدول 1: ملخص الدراسات المرجعية

QWK: مقياس الاتفاق بين درجات النموذج ودرجات المصحّح البشري، من 0 (اتفاق بالصدفة) إلى 1 (اتفاق تام).
نفس الموضوع: التدريب والاختبار على مقالات الموضوع نفسه. مواضيع جديدة: الاختبار على موضوع لم يُرَ في التدريب، وهو الإعداد الأصعب.
صفة الصلة بالموضوع (REL): مدى التزام المقال بالسؤال المطروح، وهي أضعف صفة لدى جميع النماذج.

4- الفجوة البحثية وموقع المشروع

تُظهر الدراسات السابقة ثلاث فجوات يعالجها المشروع:

- **غياب الملاحظات:** لا يوجد نظام عربي لتصحيح المقالات يولّد ملاحظات للطالب مرتبطة بالـ Rubric]2][7].
- **ضعف الصلة بالموضوع:** صفة REL هي الأضعف لدى جميع النماذج، وأعلى قيمة لها على المواضيع الجديدة 0.557 [2].
- **ضعف النماذج اللغوية وحدها في الدرجة:** تراوحت نتائجها بين 0.284 و0.575 مقابل 0.833 لنموذج AraBERT المدرَّب [1][6].

لذلك يعتمد المشروع نظاماً هجيناً: نموذج مدرَّب على LAILA يعطي درجات الصفات، مع ميزات تقارن المقال بنص الموضوع لتحسين REL؛ ووكيل ذكي يشرح الدرجات للطالب بشواهد حرفية من المقال ونص الـ Rubric دون أن يغيّرها. وتُقيَّم الدرجات بـ QWK مقارنة بالدراسات السابقة، والملاحظات بأبعاد RFE وتقييم المدرّسين.

المراجع

[1] M. Bashendy, W. Massoud, S. Eltanbouly, S. Albatarni, M. Sayed, A. Abir, H. Bouamor, and T. Elsayed, "LAILA: A large trait-based dataset for Arabic automated essay scoring," in Proc. EACL, 2026. [Online]. Available: https://aclanthology.org/2026.eacl-long.142/

[2] H. Elbahnasawi, M. Sayed, S. Eltanbouly, F. Brahamia, and T. Elsayed, "Qayyem: A real-time platform for scoring proficiency of Arabic essays," in Proc. ACL 2026 System Demonstrations, 2026. [Online]. Available: https://aclanthology.org/2026.acl-demo.53/

[3] S. Albatarni et al., "MAPLE: A meta-learning framework for cross-prompt essay scoring," in Findings of ACL 2026, 2026. [Online]. Available: https://aclanthology.org/2026.findings-acl.997/

[4] M. Bashendy, S. Albatarni, S. Eltanbouly, W. Massoud, T. Elsayed, and H. Bouamor, "TAQEEM 2025: Overview of the first shared task for Arabic quality evaluation of essays in multi-dimensions," in Proc. ArabicNLP 2025: Shared Tasks, 2025. [Online]. Available: https://aclanthology.org/2025.arabicnlp-sharedtasks.134/

[5] M. Sayed, S. Eltanbouly, M. Bashendy, and T. Elsayed, "Feature engineering is not dead: A step towards state of the art for Arabic automated essay scoring," in Proc. ArabicNLP 2025, pp. 231–245. [Online]. Available: https://aclanthology.org/2025.arabicnlp-main.19/

[6] S. Al Mandhari, H. Pham Dinh, M. El-Haj, and P. Rayson, "Structured prompting for Arabic essay proficiency: A trait-centric evaluation approach," in Proc. LREC 2026, pp. 10532–10544. [Online]. Available: https://aclanthology.org/2026.lrec-1.826/

[7] K. Dahimi, H. Cherroun, and A. Belabbaci, "Automated scoring of Arabic text using large language models: A literature review," in Proc. NCMAI'26, 2026, arXiv:2606.09830. [Online]. Available: https://arxiv.org/abs/2606.09830

[8] X. Jin, J. Zhang, T. Cao, and B. Yang, "Beyond score prediction: LLM-based essay scoring and feedback generation via reinforcement learning with rubric rewards," arXiv:2607.19219, 2026. [Online]. Available: https://arxiv.org/abs/2607.19219

[9] S. Eltanbouly, S. Albatarni, and T. Elsayed, "TRATES: Trait-specific rubric-assisted cross-prompt essay scoring," in Findings of ACL 2025, pp. 20528–20543. [Online]. Available: https://aclanthology.org/2025.findings-acl.1054/